A 股横截面多因子选股：点时数据、风险中性化与可成交归因

研究期间： 2006-01-04 至 2026-09-30

训练 / 验证 / historical OOS： 2006–2015 / 2016–2020 / 2021–2026

最终研究状态： 代码、配置、测试、数据血缘、失败实验和 31 个不可变实验版本已纳入统一治理。

摘要

本项目从免费数据源重建 5,521 只历史 A 股的点时研究池，构造 15 个量价、流动性和估值因子，以 t 日收盘信息形成信号、最早于下一交易日收盘执行，并用按年扩展窗口训练 Ridge 与 HGB 横截面排序模型。研究进一步完成 PIT 证监会宽行业与规模中性化、组合层行业/规模/单股/换手约束、停牌和涨跌停订单逐日重试、多因子风险归因、CAPM 与本地六风格时间序列归因。

最终可成交结果并非“发现了稳定纯个股 Alpha”。在 2021–2026 historical OOS 的 1,387 个非重叠日频净值日上，20bp 线性成本后的原始 HGB / Ridge 约束组合年化分别为 20.81% / 17.80%，Sharpe 为 0.94 / 0.86，最大回撤为 -33.32% / -32.99%。但加入 CSI500 与六个 PIT 自融资风格因子后，四条组合的年化残余 Alpha 仅为 -2.55% 至 +1.07%，Newey–West 95% 区间全部跨零，约 89.4%–89.8% 的日收益波动可由市场和风格解释。最诚实的结论是：策略捕捉到可执行、受约束的本地风格溢价，尚未证明稳定的纯选股 Alpha。

1. 研究问题

研究按顺序回答五个问题：

- 传统 A 股横截面因子在严格点时信息与可执行标签下是否仍有预测力？
- 行业与规模中性化后，信号是否仍存在？
- HGB 等非线性模型相对 Ridge 是否提供稳定增量？
- 收益能否承受行业、规模、换手、容量、停牌、涨跌停和成本约束？
- 最终收益究竟来自市场、行业、风格还是股票特异部分？

2021–2026 已在研发过程中被多次查看，因此全文称为 historical OOS，不称为 pristine lockbox，也不代表实盘业绩。

2. 数据与点时设计

- 主源为 BaoStock，AKShare 只用于确定性抽样核对，不静默覆盖主源。
- 历史 A 股并集 5,521 只，下载覆盖率 100%；完整数据湖约 11 GiB，不上传 GitHub。
- 历史证券快照延迟到下一交易日生效，避免用今天仍上市的股票回填历史。
- 证监会宽行业按月末及首个信号日抽取 250 个历史快照，严格 backward as-of join；最低年度覆盖率 98.55%。
- 原始行情、质量层、因子、标签、模型特征、预测、持仓和成交分层保存为 Parquet，并在 manifest 中记录请求、schema、行数和内容哈希。
- 两个被分页边界静默截断的行业证券快照已被识别、隔离、重新下载并触发下游重算；旧实验不覆盖，而是登记 invalidation 与替代版本。

2.1 信息时序

因子只使用 asof_date=t 收盘前可观察字段，available_date 映射到下一交易日。5 日标签覆盖完成入场后的 t+2 至 t+6 收益，而不是把无法成交的 t+1 当日收益计入策略。训练、验证和 historical OOS 边界均按标签跨度 purge。

2.2 可交易性

最终执行器使用股数订单和唯一日频净值时钟：新目标在下一交易日收盘提交；停牌、涨停买单和跌停卖单保留未成交股数并逐日重试；新周目标取消旧订单；自然价格漂移不会触发隐藏的日频再平衡。

3. 因子研究

机器可读 factor registry 记录每个因子的公式、单位、原始字段、观察窗口、缺失机制、理论方向和 2006–2015 训练期锁定方向。15 个因子覆盖动量、反转、风险、流动性/关注度、量价关系与价值。

预处理只在同一信号日截面内进行：1%/99% quantile winsor、缺失值中位数填补及缺失指示、z-score。所有方案在同样本上完成消融；选择仅使用训练与验证期。

PIT 行业+规模中性化后的单因子 tear sheet 覆盖 293 个 historical OOS 周、十分位组合、Top–Bottom、双腿换手、年度和市场状态。14/15 个因子的毛 Top–Bottom 年化算术价差块 bootstrap 下界高于零，earnings_yield 例外；但这只是未建模融券与涨跌停的诊断组合，不是可交易多空业绩。down_high 状态下波动率、振幅、盈利收益率和账面市值比的定向 RankIC 非正，说明全样本显著性不等于跨状态稳健。

因子分布图显示 earnings_yield 的 historical OOS 缺失率约 21.1%，显著高于其他因子；52 周滚动横截面相关表明长动量与波动/振幅的关系会发生明显时变。相关性与分布只作描述，不据此在 historical OOS 上重选因子。

[图表见仓库 HTML/SVG：验证期因子相关性]

[图表见仓库 HTML/SVG：历史样本外因子分布]

4. 模型比较与参数稳健性

统一基准在相同因子、标签、时间切分、候选池和成本口径下比较 naive、OLS、Ridge、ElasticNet、RandomForest 与 HGB。验证期选择 hgb_shallow15；historical OOS 平均 RankIC 为 HGB 0.0999、Ridge 0.0976。模型组合指标属于理想完整成交口径，不能替代最终日频执行结果。

HGB 的 3×3 二维稳定面只使用 2006–2015 训练与 2016–2020 验证。9 个叶节点/L2 坐标的全验证期 RankIC 位于 0.0971–0.0998，排序能力较平坦；五个单年最优坐标却分散在三个参数点，理想成交组合收益也高度不稳定。因此保留浅层、已锁定模型，不追逐验证期收益最高坐标。

早期 RF 参数邻域只有 70% 通过预设稳健性门槛，且 RF 对次日涨停/停牌的小盘股票集中度高。该负面结果没有删除，而是触发了专门的执行取证与最终日频重试引擎。

5. 中性化与组合约束

锁定模型分别使用 raw 与 industry+size-neutralized 因子。中性化使 Ridge historical OOS RankIC 从约 0.0986 降至 0.0900，并显著降低其理想组合收益；HGB 的 RankIC 同样下降，但收益差异区间跨零。因子分数正交后，Top-200 的行业主动权重没有自动下降，说明“因子中性”不等于“组合中性”。

最终线性规划组合固定 Alpha 后施加：

- 单股权重不超过 0.5%；
- 各宽行业相对研究池主动权重在 ±3% 内；
- 组合绝对规模暴露不超过 0.10；
- 周度单边换手目标不超过 30%；
- 所有约束使用信号日可得的 PIT 暴露。

293 周全部成功求解且没有放宽换手上限。原始 HGB 约束组合的周频理想成交年化为 24.68%、Sharpe 0.92、最大回撤 -32.90%；行业主动权重 L1 降至约 0.095。该数字仍不是最终可成交结果。

6. 最终日频可成交表现

下表使用 20bp 线性成本、停牌/涨跌停逐日重试和 1,387 个唯一日频净值日：

模型	Alpha 管线	年化收益	年化波动	Sharpe	最大回撤
HGB	raw	20.81%	23.02%	0.94	-33.32%

模型	Alpha 管线	年化收益	年化波动	Sharpe	最大回撤
HGB	industry+size neutral	20.26%	21.91%	0.95	-31.53%
Ridge	raw	17.80%	21.98%	0.86	-32.99%
Ridge	industry+size neutral	15.87%	21.60%	0.79	-31.71%

相对理想全成交上界，四条策略的成交折损年化算术区间均低于零；raw HGB 的 95% 区间为 [-1.66%, -0.68%]。这证明涨跌停/停牌影响虽不是灾难性的，却不能忽略。

固定实际成交路径的线性费率压力测试中，raw HGB 在 0/20/50/100bp 下的年化约为 24.76% / 20.82% / 15.13% / 6.23%；100bp 仍为正，但 Sharpe 仅 0.38。该测试不包含费用改变股数路径、税费或真实冲击反馈，因此只是边界，不是资金承诺。

Top50/100/200/500 与等权/inverse-vol 的共同日期回顾诊断显示：inverse-vol 在验证期改善 Sharpe，但在 historical OOS 对所有 Top-N 都弱于等权。它不替换已锁定政策，也说明权重方案不能凭单一区间改选。

7. 风险与收益归因

周频多因子风险模型包含 20 个证监会宽行业和 size、beta、volatility、liquidity、value、momentum 六风格；截面因子收益、EWMA 收缩协方差和特异风险都只使用当期及之前数据。

raw HGB 约束组合的年化算术风格贡献约 13.61%，95% 区间 [6.22%, 20.06%]；股票特异贡献约 -0.43%，区间 [-3.52%, 3.08%]。行业主动贡献接近零。组合层约束控制了行业和规模，但收益仍主要来自流动性、波动、动量/反转等风格。

日频 CAPM 相对 CSI500 的四条 Jensen Alpha 为 13.60%–17.92%，Newey–West 95% 区间下界均高于零，Beta 约 0.74–0.78。但 CSI 指数是价格指数、无风险利率按零处理，CAPM 截距不能直接解释为纯选股 Alpha。

为交叉验证，项目用 PIT A 股截面构造 size、beta、volatility、liquidity、value、momentum 六个净投资为零、总杠杆为 2 的自融资组合，并先对宽行业与其余风格残差化。加入 CSI500 与六风格后：

模型	Alpha 管线	年化残余 Alpha	95% 区间	R^2
HGB	raw	1.05%	[-5.83%, 7.92%]	0.895
HGB	industry+size neutral	1.07%	[-5.62%, 7.76%]	0.898
Ridge	raw	-1.74%	[-8.56%, 5.08%]	0.896
Ridge	industry+size neutral	-2.55%	[-9.58%, 4.49%]	0.894

最大 VIF 2.04、标准化设计条件数 2.74，结论不是明显多重共线性造成。CAPM 的显著截距大部分被本地风格吸收。

8. 被拒绝的策略与研究治理

第一版风险感知优化将 raw HGB 预测跟踪误差从约 8.07% 降至 4.43%，但年化收益从 24.68% 降至 18.69%；配对收益差 95% 区间 [-8.24%, -0.80%]。20% target-vol 层也没有改善 Sharpe。因此该政策被正式拒绝，没有在已查看的 historical OOS 上继续调风险预算。

每个正式实验保存解析后配置、代码树哈希、环境、输入 SHA-256、指标和不可覆盖 FROZEN.json。当前 publication audit 为 0 FAIL；旧实验因数据修复产生的 live-input drift 保持 WARN，并在 experiment_invalidations.yaml 中记录原因和替代版本，快照自身仍须通过完整性检查。

这套治理保留了三类不漂亮但重要的证据：预处理组合曾存在 outcome-availability leakage、RF 理想成交收益被涨跌停显著放大、首版风险优化降低风险却显著损害收益。

9. 局限与不可伪装的未完成项

- 行业是月度抽样的历史证监会宽行业，不是带精确生效日的申万细分行业或商业风险模型。
- 股票池是历史 A 股可交易代理，不是官方历史 CSI 成分。
- 指数不含股息，无风险利率按零；盈利/投资因子缺乏可靠的完整 PIT 公告数据。
- 未建模印花税变化、真实撮合队列、融券可得性、基金申赎及券商校准冲击。

- 100bp 测试是固定成交路径重定价；容量模型仍是情景分析。
- 没有 paper/live 记录；所有结果均为研究回测。
- historical OOS 已被查看，下一步真正的验证应来自未来新增数据或纸面交易，而不是继续调历史参数。

10. 结论

项目完成了从免费数据下载、PIT 数据库、横截面因子、验证期选模，到风险中性化、组合约束、日频执行和风格归因的闭环。最终策略在保守但仍简化的成交假设下保持正收益；同时，多因子归因否定了“显著纯选股 Alpha”的更强说法。

这项研究最有价值的部分不是一条净值曲线，而是能用同一条可审计链路解释：哪些信号存在、哪些收益来自结构性风格、哪些模型增量不稳定、哪些执行假设曾高估结果，以及什么证据会改变当前结论。